Sephora Customer Segmentation

On the Grill #2 — Groupe 10

63 179	400K	7	18	0.234
clients analysés	transactions	segments	features	silhouette(Ward)

A. Retrospection — What Changed Since Grill #1

Feedback reçu : "Le plus important sera d'interpréter les clusters et d'en faire des clusters targetables — pas forcément les plus performants techniquement, mais utiles pour les marketeurs."

Ce que nous avons changé :

• **Nommage actionnable :** chaque cluster porte un nom métier (Champions Multi-Marques, Chasseurs de Promos Online…) et une stratégie marketing explicite, pas seulement un numéro.

• **Features orientées usage :** comme is_discount_hunter, pct_online, top_brand_share, loyal_to_first_brand...

• **Profiling enrichi :** la heatmap et les radar charts permettent de bien interpréter les clusters.

• **Roadmap item :** nous prévoyons encore d'ajouter la saisonnalité (% achats été, week-end) comme feature de ciblage dans la prochaine itération.

B. Analysis — Method, Results & Baseline

Méthode : Clustering hiérarchique Ward (k=7) sur 18 features scalées + PCA (10 composantes, 90 % de variance). Ward minimise la variance intra-cluster, adapté à des profils clients hétérogènes en taille. K-Means et GMM ont été comparés — Ward retenu pour son meilleur Silhouette (0.234 vs 0.231 K-Means, 0.097 GMM). Et filtrage des outliers avec un Isolation Forest (2% des données).

Résultats — 7 segments actionnables :

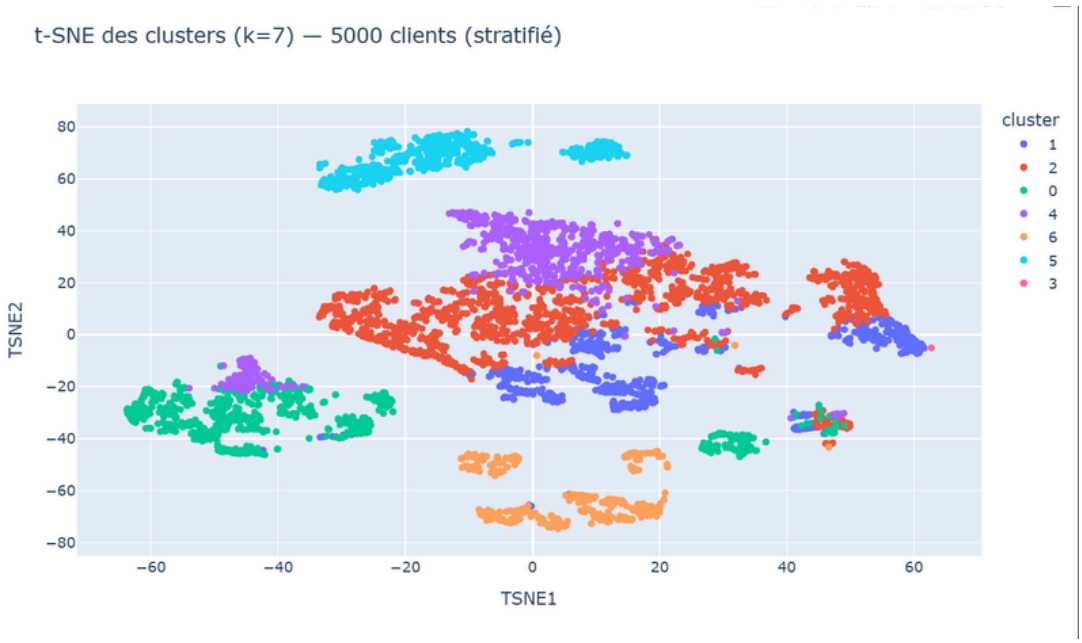

Cluster	Signaux clés	Persona
0	basket 60.9€, discount 0.2, discount_hunter=1, âge 44	Acheteurs Premium Opportunistes
1	recency 272j, freq 1, tenure 294j, inactif	Clients Perdus
2	recency 60j, freq 2, basket 24€, tenure 142j	Acheteurs Occasionnels
3	recency 354j, monetary **0.2€**, top_brand_share **334** ⚠️	Anomalie (retours/avoirs)
4	recency 25j, freq 5, CA 339€, 6 marques	Champions Multi-Marques
5	recency 30j, omnichannel=1, âge 32, CA 255€	Omnicanaux Connectés
6	loyal_to_first=1, freq 1, âge 32, recency 105j	Mono-Marque Inactifs

D. Roadmap — Path to the Finish Line

Ce qu'il reste à faire et faiblesses actuelles

- Ajouter des dimensions à notre analyse :
  - saisonnalité par catégories et pour chaque cluster
  - d'autres variables pour la classification notamment concernant la démographie
- Amélioration de la scalabilité : complexité algorithmique actuelle $O(n^2 \ln(n))$, l'algorithme actuel ne permet pas de traiter l'ensemble des données.
- Amélioration de la qualité des clusters et peut être changement de modèle
- Travailler davantage sur l'interprétation des personas notamment à travers l'amélioration de la visualisation
- Envisager de ne pas faire de PCA pour améliorer l'interprétable.